

MASTER MIAGE 2ÈME ANNÉE
UNIVERSITÉ PARIS NANTERRE

MÉMOIRE DE FIN D'ÉTUDES

**Méthodes d'analyse des processus
métier pour le choix d'une
architecture Big Data adaptée**



Auteur :
LUDWIG SIMON

Tuteur :
MCF. EMMANUEL HYON

Février 2019 — Juin 2019

Remerciements

Je tiens tout d'abord à remercier mon tuteur, monsieur Emmanuel Hyon qui m'a suivi toute l'année pendant la rédaction de mémoire. Les conseils et l'aide qu'il a pu m'apporter sur la rédaction de ce dernier m'ont vraiment été très utiles.

J'aimerais aussi remercier mes collègues d'EDF avec qui j'ai pu travailler dans de bonnes conditions tout au long de l'année. Je les remercie aussi pour le temps qu'ils m'ont accordé afin de répondre à mes interrogations sur le domaine du Big Data pour m'aider dans la rédaction de ce mémoire.

Résumé

Le Big Data est de plus en plus présent aujourd'hui, et pourtant ce sujet reste trop vague pour un trop grand nombre de personnes qui se laisse aveugler par la popularité d'une technologie pour concevoir leur architecture Big Data.

De plus certaines entreprises tentent le Big Data sans avoir de cas utilisation concret, cela engendre une architecture complexe et chère à maintenir alors qu'ils n'en ont nullement l'utilité.

Dans un premier temps, nous allons brièvement rappeler ce qu'est le Big Data et montrer à partir de quand il est intéressant de l'utiliser.

Dans un second temps, nous allons faire un état des lieux des composants qui composent une architecture Big Data et après nous allons nous intéresser aux différents modèles d'architectures Big Data existants.

Ensuite, nous allons nous parcourir les différentes solutions logicielles intervenant dans les architectures Big Data que nous avons étudiées. Cela permettra d'analyser leur fonctionnement afin de trouver des critères de sélection.

Dans une troisième partie, nous établirons les critères permettant de départager les différentes architectures Big Data ainsi que les différentes solutions logicielles permettant la réalisation de celles-ci.

Finalement, nous définirons une manière d'évaluer notre choix d'architecture afin de vérifier que c'est bien la solution optimale.

Motivations

Avant d'avoir commencé mon stage de Master 1 chez EDF dans le service Big Data, pour moi le Big Data était une notion très floue et je ne savais pas vraiment tout ce qui composait ce domaine. Durant ce stage j'ai pu découvrir ce domaine et me rendre compte du nombre conséquent d'outils différents qui sont nécessaires pour la conception d'une architecture Big Data complète. C'est à partir de ce moment-là que je me suis demandé, comment est-ce que le choix de l'architecture, et des outils Big Data s'effectue ? Il y a beaucoup plus de possibilités que dans les domaines que j'ai pu voir jusqu'à maintenant. C'est pour cela que j'ai décidé cette année, d'essayer de comprendre comment fonctionne une architecture Big Data afin de trouver une solution pour choisir plus facilement une architecture Big Data adaptée à nos besoins.

Objectifs

À travers ce mémoire j'aimerais dans un premier temps vous rappeler ce que c'est que le Big Data. Le Big Data étant devenu à "la mode", je pense qu'il est important de rappeler ce que c'est exactement et quand il est intéressant de l'utiliser.

Dans un second temps, je voudrais vous montrer à quel ce domaine est vaste et à quel point c'est important de se renseigner de manière régulière sur les nouveautés afin de ne pas faire un choix basé uniquement sur la popularité d'un outil. Il est important de faire soit même ses recherches sur les différents outils à notre disposition afin d'utiliser celui qui correspond le mieux à nos utilisations.

Et pour finir, j'aimerais définir des critères permettant à partir d'un cas d'utilisation, de nous proposer la meilleure architecture Big Data.

Sommaire

1	Les architectures Big Data	9
1.1	Architecture Lambda	11
1.2	Architecture Kappa	14
2	Analyse des solutions logicielles existantes	17
2.1	Message Broker	17
2.2	Ingestion/Extraction de données	19
2.3	Traitement des données	21
2.4	Stockage des données	24
2.5	Requêtage des données	33
2.6	Visualisation et Analyse des données	33
2.7	Orchestration	34
3	Critères d'analyse	37
3.1	Sélection d'architecture en entreprise	37
3.2	Critères pour le choix de l'architecture	38
3.3	Critères pour le choix des solutions logicielles	39
3.4	Pour aller plus loin	42
4	Comment évaluer l'architecture résultant de l'application des critères	45
4.1	Application des critères définis sur des cas d'utilisations réels	45
4.2	Évaluation des résultats	45
	Annexe A Les différents concepts du Big Data	49
A.1	Architecture Réactive	49
A.2	Architecture Répartie	51
	Bibliographie	53

Introduction

Le Big Data

La démocratisation des ordinateurs et l'avènement du WEB 2.0 ont entraîné une digitalisation de nos connaissances. Aujourd'hui, 95% de celles-ci sont numérisées et la production de données est en constante évolution. Notre société produit quotidiennement 2.5 exaoctets de données (l'équivalent de 90 années de vidéos, ou 2,5 millions de téraoctets) et en 2020 il est estimé que 35 zettaoctets seront produits (1 zettaoctet = 1000 exaoctets). Les réseaux sociaux et les objets connectés participent grandement à cette augmentation considérable du volume de données.

On caractérise le domaine du Big Data à l'aide de cinq facteurs appelé les 5V du Big Data [1] (Figure 1).




Figure 1 – Schéma des 5V du Big Data

- **Le volume** décrit la quantité de données générée. Il s'agit donc de la possibilité de gérer une masse de données créées quotidiennement. Par exemple, Facebook stocke aujourd'hui plus de 250 milliards d'images.
- **La vélocité** représente la vitesse à laquelle les données arrivent. Un des meilleurs exemples pour représenter la vélocité est l'ajout de vidéos sur la plateforme Youtube. En effet, chaque minute, ce sont pas moins de 400 heures de vidéos qui sont uploadées sur la plateforme.
- **La variété** correspond aux diverses natures que peuvent avoir les données. Par exemple, Twitter stocke du texte, des images, des fichiers vidéo, des métadonnées, etc.
- **La véracité** met en avant la dimension qualitative nécessaire au bon fonctionnement des outils Big Data. Lorsque les données ne sont pas qualitatives, il n'est pas possible de les traiter et de s'en servir correctement.

- **La valeur** est la plus importante des 5V. Les données auquel on s'intéresse doivent avoir une valeur réelle pour que les analyses que l'on veut effectuer ne soient pas fossés. Il est donc important de trier les données avant leur exploitation.

Quand peut-on utiliser le Big Data ?

Le Big Data étant aujourd'hui "à la mode", c'est-à-dire que tout le monde en entend parler et donc veut aussi l'utiliser. Le problème étant que le Big Data n'est pas toujours la solution idéale pour les applications que l'on souhaite réaliser. En effet, le Big Data a été créé dans les cas où une seule machine n'est plus suffisante pour les opérations que vous avez besoin d'effectuer. Par exemple, si vos traitements de données s'effectuent sans aucun problème sur votre machine et que votre base de données n'a aucun souci de performance en étant installée sur une seule machine, il n'y a pas de réel intérêt pour vous de passer à une architecture Big Data. Dans le cas où une seule machine n'est plus suffisante pour vos besoins, avant de passer à une architecture Big Data vous pouvez essayer d'améliorer votre machine en changeant ses composants. Vous pouvez aussi essayer de rendre certaines parties de votre code asynchrones, afin d'améliorer les performances de votre code et de répartir son exécution au mieux sur votre machine. C'est ce qu'on appelle la mise à l'échelle verticale, c'est la première étape avant de passer à la mise à l'échelle horizontale (A.2) qui est l'un des atouts principaux du Big Data. Une fois toutes ces étapes appliquées, si votre architecture n'arrive toujours pas à suivre le rythme voulu, cela veut dire que votre application est propice à l'utilisation d'une architecture Big Data. Comme vous venez de le voir, ce n'est malheureusement pas possible de définir une limite chiffrée pour définir quand l'utilisation du Big Data est requise. Cette limite peut varier en fonction du format des données reçues, de la complexité des traitements effectués sur les données, etc. Bien évidemment dans certains cas l'utilisation du Big Data est évidente (Exemple : des plateformes comme YouTube et Facebook), mais dans le cas où vous n'avez encore jamais fait de Big Data et que vous n'avez pas un nombre de données immense, il est préférable de ne pas se diriger tout de suite vers le Big Data.

Les architectures Big Data

Une architecture Big Data est un regroupement d'outils permettant de gérer des données de leurs ingestions à leurs mises en valeur via des analyses. Il faut savoir qu'il existe plusieurs architectures dans le domaine du Big Data, et qu'elles répondent à des besoins différents. Nous allons nous intéresser aux deux architectures les plus importantes, étant donné que les autres sont des dérivées des deux architectures principales. Avant de voir en détail ces deux architectures, nous allons voir de manière plus générale les différents composants qui peuvent se retrouver dans des architectures Big Data [2][3]. Les différents composants pouvant se retrouver dans une architecture Big Data sont illustrés sur la figure 1.1.

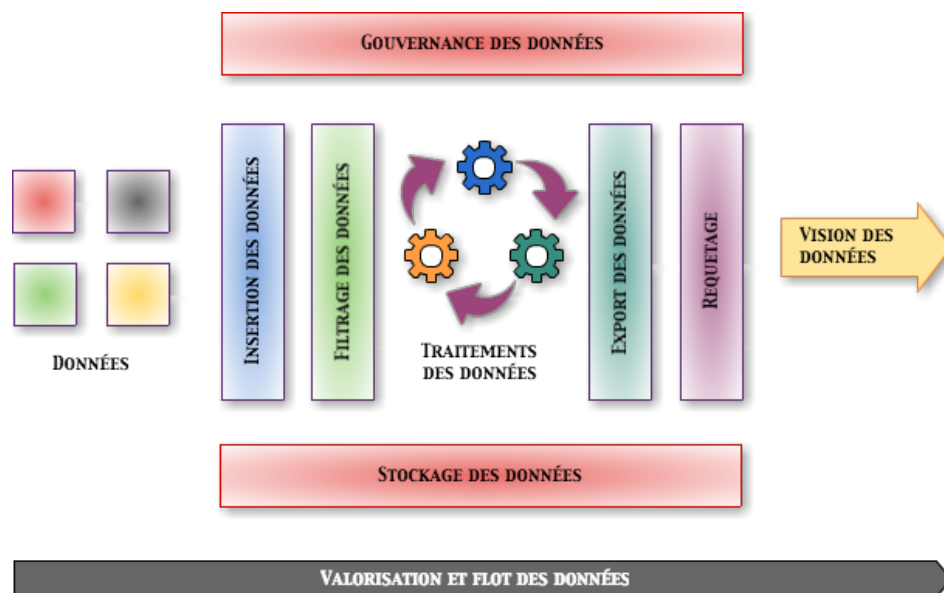


Figure 1.1 – Composants d'une architecture Big Data

Nous allons maintenant détailler le rôle de chaque composant présenté dans le diagramme ci-dessus.

- **Source de données :** N'importe quelle solution Big Data a besoin d'une source de donnée en entrée. Voici quelques exemples de données qui peuvent être utilisées dans une architecture Big Data
 - Des données issues de bases de données relationnelles.
 - Des fichiers statiques produits par des applications, des fichiers de logs par exemple.
 - Des sources de données en temps réel, par exemple des données de capteurs récupérés via des appareils IoTs.

- **Ingestion des données** : La solution doit être capable d'aller chercher directement les données dans les différentes sources. Il est possible que les données soient directement envoyées dans la chaîne de traitement des données, mais c'est rarement le cas. Afin d'aller récupérer les données à la source, il y a plusieurs solutions. On peut écrire un programme permettant d'extraire les données. Cette solution est la plus efficace si le programme répond bien aux contraintes du Big Data, c'est à dire, il faut qu'il soit le plus réactif possible et le plus facilement adaptable aux flux de données entrants (Architecture réactive A.1). La seconde solution, la plus simple, est l'utilisation d'un ETL (Extract Transform Load). C'est un outil graphique permettant de configurer l'extraction des données et leurs insertions dans la chaîne de traitements ou dans la solution de stockage. Néanmoins, cette solution est plus gourmande que l'écriture d'un programme, car elle doit être capable de gérer énormément de sources et d'opérations différentes.
- **Traitement par lot** : Les jeux de données étant trop lourds lors d'un traitement par lots, il est nécessaire de pouvoir exécuter une tâche de traitement de longue durée afin de filtrer, agréger et préparer les données en vue de leur analyse. En général, ce genre de traitement implique une lecture de fichier source et une écriture dans de nouveaux fichiers. Le traitement des données peut s'effectuer par des programmes Java, Scala ou Python ou encore via des outils spécialisés comme MapReduce ou Spark.
- **Ingestion des données en temps réel** : Si la solution doit interagir avec des sources de données en temps réel, l'architecture doit impérativement implémenter un moyen de récupérer ces données et de les stocker temporairement dans une file d'attente afin de pouvoir les temporiser. Cela permet d'éviter la perte de données entrante, et permet d'envoyer les données à la solution de traitement quand elle est disponible et de ne pas la surcharger. Généralement, on utilise des messages brokers pour ce genre de tâches.
- **Traitement de flux** : Une fois les données récupérées, elles doivent être filtrées, agrégées puis préparer pour l'analyse. Le traitement est similaire au traitement par lot, seuls les outils sont différents, car ils doivent être capables de gérer le traitement en temps réel.
- **Stockage des données** : Une solution de stockage de données est indispensable dans le cas de traitement des données par lot (??), et peut s'avérer utile lors de traitements des données en temps réel (??) si l'on souhaite conserver les données reçues en plus de les traiter. Le deuxième cas ou un stockage de donnée peut être utile pour le traitement en temps réel, est si l'on a besoin d'agréger des données statiques avec les données en temps réel. Ces solutions de stockage doivent être capables de gérer divers formats de données, et surtout ils doivent être distribués (A.2).
- **Gouvernance des données** : La gouvernance des données correspond à l'ensemble des procédures mises en place afin d'encadrer la collecte des données ainsi que leur utilisation. La gouvernance des données comprend quatre dimensions. La disponibilité des données, l'utilisabilité des données, l'intégrité des données et la sécurité des données.
- **Requêtage** : Afin de pouvoir fournir les données stockées aux outils d'analyse

et de visualisation, l'utilisation d'un outil de requête peut être requis. Dans certains cas votre base de données et votre outil de visualisation communiqueront directement entre eux, mais dans d'autres cas vous aurez besoin d'utiliser un outil de requête afin de fournir les données au bon format et de pouvoir faire une sélection des données à envoyer à l'outil.

- **Analyse et visualisation des données** : La dernière étape dans une architecture Big Data est la visualisation/analyse des données. La plupart des solutions Big Data ont pour but de faire de la valorisation de données et de fournir au minimum une visualisation des données et au mieux d'effectuer des analyses dessus. Cela peut se faire par l'écriture de rapport ou bien par application d'algorithme afin de détecter et de montrer différentes corrélations entre des données par exemple. Le but principal est d'avoir une visualisation intelligente et facilement compréhensible de données étant à la base illisible par l'homme.
- **Orchestration** : La majorité des solutions Big Data consistent à effectuer des traitements de données répétés, ayant pour but de transformer les données sources puis de les stocker ou bien les envoyer directement à un outil d'analyse ou de visualisation des données. Il est donc important d'avoir un outil permettant de paramétrer les différentes actions que l'on souhaite effectuer sur nos données.

Comme on peut le voir, une architecture Big Data possède beaucoup de catégories, et l'on constate qu'une catégorie existe sous 2 formes, le traitement des données. Les deux architectures différentes sont justement tournées sur cette catégorie, et proposent chacune une vision différente du traitement des données. Ces deux architectures sont l'architecture Lambda et l'architecture Kappa [4][3][5].

1.1 Architecture Lambda

L'architecture Lambda est une technique de traitement de données capable de traiter efficacement une grande quantité de données. L'efficacité de cette architecture provient d'un débit accru, une latence réduite et d'erreurs négligeables. Cela mène jusqu'à des applications pratiquement en temps réel. Dans le domaine du machine learning (Apprentissage automatique), cela permettrait aux développeurs de définir des règles delta.¹ sous la forme code logique ou de traitement de langage naturel avec des modèles de traitement de données basés sur des événements afin d'obtenir de la robustesse, de l'automatisation et d'améliorer la qualité des données. Pour faire simple, toute modification de l'état des données est un événement pour le système, et il est possible de répondre à cet événement via l'exécution d'une commande ou d'une procédure delta.

La récupération d'événements est un concept qui consiste à utiliser les événements afin d'effectuer des prévisions ou bien stocker les changements effectués sur le système en temps réel. Par exemple, une personne qui interagit sur un site de réseau

1. La règle Delta est une règle d'apprentissage de la descente sur gradient permettant de mettre à jour les poids des entrées des neurones artificiels dans un réseau de neurones à une seule couche

social va provoquer des événements lors du chargement d'une page, de l'ajout en favoris d'un post, ou bien lors d'une demande d'ajout en ami. Ces événements peuvent être stockés en base de données ou bien traités afin d'enrichir des données déjà présentes.

Le traitement des données traite les flux d'événements, ces événements sont stockés dans un système de données en direct. L'architecture Lambda permet le traitement des données en introduisant trois couches distinctes :

- **Batch Layer**, couche de traitement par lots.
- **Speed Layer/Stream Layer**, couche de traitement de flux
- **Serving Layer**, couche de service.

Batch Layer

Les données arrivent constamment comme un flux vers le système de données. Tout nouveau flux de données entrant dans la couche de traitements par lots est calculé et traité sur un lac de données ².

Speed Layer

La couche vitesse se sert des résultats fournis par la couche de traitement par lots. Les flux de données entrants peuvent provenir de source extérieure (Ex. appareils IoT), ou bien d'événement qui ont été créés lors du traitement des données sur la couche de traitement par lots. Le second cas est spécialement vrai si l'on veut effectuer du machine learning (??), afin de faire de la prédiction sur les prochaines données qui vont arriver. Comme son nom l'indique, la couche vitesse a une faible latence, car elle ne traite que des données en temps réel contrairement à la couche de traitements par lots.

Serving Layer

Les sorties de la couche de traitement par lots sont sous la forme de vues par lots, et celles de la couche vitesse sont sous la forme de vues en quasi temps réel. Ces vues sont transmises à la couche de service, qui va utiliser ces données afin de stocker ces vues et donc les rendre accessibles au client qui va les exploiter à l'aide d'outil d'analyse et de visualisation.

la figure 1.2, représente un diagramme basique de ce à quoi ressemble le modèle de l'architecture lambda.

2. Un lac de données (en anglais Data Lake) est une méthode de stockage des données utilisée par le Big Data. Ces données sont gardées dans leurs formats originaux ou sont très peu transformées.




Figure 1.2 – Schéma de l'architecture Lambda

Traduisons ce fonctionnement en une équation fonctionnelle qui définit toute requête dans le domaine du Big Data. Les symboles utilisés dans cette équation sont connus sous le nom de "Lambda" et c'est de là que cette architecture s'est vu ce nom attribué.

$$\text{requête} = \lambda(\text{Données complètes}) = \lambda(\text{Données temps réel}) \times \lambda(\text{Données stockées})$$

Cette équation signifie que toutes les requêtes relatives aux données peuvent être traitées dans l'architecture Lambda en combinant les résultats du stockage historique issue tu traitement par lots et des données en temps réel.

Applications de l'architecture Lambda

L'architecture Lambda peut être déployée dans les cas suivants :

- Le résultat des requêtes des utilisateurs ne doit être calculé que lorsque les requêtes sont émises (pas de système de cache du résultat des requêtes).
- Les réponses doivent être rapides et le système doit être capable de gérer diverses mises à jour sous la forme de nouveau flux de données.
- Aucun des enregistrements stockés ne doit être effacé, mais l'ajout et la modification d'enregistrement doivent être possibles.

L'architecture Lambda peut être considérée comme une architecture de traitement de données en temps quasi réel. Comme nous l'avons mentionné précédemment, elle est tolérante aux pannes et évolutive. Elle possède une couche de traitements par lots et une couche vitesse de traitements en temps réel. Et elle garantit un stockage permanent des données. Cette architecture est utilisée par des entreprises comme Twitter, Netflix et Yahoo pour répondre aux normes de qualité de service.

Avantages et inconvénients de l'architecture Lambda

Nous allons maintenant voir à partir de tout ce qu'on a vu de cette architecture, qu'elles sont ses avantages et inconvénients.

Avantages

- La couche de traitement par lots gère les données historiques avec un stockage distribué à tolérance de pannes, ce qui réduit les risques d'erreurs, même en cas de panne du système.
- Les données fournies au client sont les plus fraîches possible.
- Architecture à tolérance de pannes et évolutive pour le traitement des données.

Inconvénients

- La logique est implémentée deux fois (couche vitesse et couche de traitement par lots).
- Le fait de retraiter chaque traitement par lots n'est pas utile dans tous les cas.
- Il existe des solutions plus simples lorsque le besoin n'est pas complexe.

1.2 Architecture Kappa

En 2014, Jay Kreps a entamé une discussion au cours de laquelle il a souligné certaines divergences dans l'architecture Lambda. L'architecture Kappa est née en réaction à la complexité de l'architecture Lambda, notamment avec la division du traitement par lots et du traitement en temps réel.

L'architecture Kappa ne peut en aucun cas être considérée comme un substitut de l'architecture Lambda. Au contraire, elle doit être considérée comme une alternative à celle-ci, spécifiquement dans les cas où la couche de traitement par lots n'est pas au premier plan. La figure 1.3 présente le fonctionnement de l'architecture Kappa.

Traduisons le fonctionnement du traitement dans cette architecture en une équation fonctionnelle qui définit toute requête dans le domaine du Big Data.

$$\text{requête} = \kappa(\text{Nouvelles données}) = \kappa(\text{Flux de données en temps réel})$$

Cette équation montre que toutes les requêtes peuvent être traitées par l'application de la fonction kappa au flux de données en temps réel sur la couche de service.

Applications de l'architecture Kappa

L'architecture Kappa peut être déployée dans les cas suivants :




Figure 1.3 – Schéma de l'architecture Kappa

- Plusieurs évènements ou requêtes sont stockés dans une file d'attente avant d'être traités un par un.
- L'ordre des évènements n'est pas prédéfini, et la couche de traitement de données en temps réel doit être en mesure d'interagir avec le système de stockage n'importe quand.
- Afin de traiter des téraoctets de données, il est nécessaire que chaque nœud soit hautement disponible, résilient et supporte la réplication.

L'architecture Kappa est utilisée par des entreprises comme LinkedIn.

Avantages et inconvénients de l'architecture Kappa

Nous allons maintenant voir à partir de tout ce qu'on a vu de cette architecture quels sont ses avantages et inconvénients.

Avantages

- Le retraitement des données est requis uniquement lorsque le code est modifié.
- Solution moins complexe que l'architecture Lambda.
- Moins de ressources requises étant donné que le traitement se fait en temps réel.

Inconvénients

- Pas de séparation entre les besoins (Temps réel et traitements par lots).
- L'absence de couche de traitement par lots peut entraîner des erreurs lors du traitement des données ou lors de la mise à jour de la base de données.

Pour conclure sur ces deux architectures, l'architecture Lambda est beaucoup plus complète que l'architecture Kappa mais cela au prix d'une complexité accrue. De nombreux cas d'utilisation en temps réel conviendront parfaitement à une architecture Lambda. On ne peut pas en dire autant de l'architecture Kappa. Dans des cas où le traitement des données par lots et en temps réel sont similaire, ou bien, si le but est principalement de fournir des données métiers aux clients, l'utilisation de l'architecture Kappa est une bonne solution. Par contre dans les cas où les traitements de données en temps réel et par lots sont complètement différents ou bien si vous avez besoin d'utiliser des modèles d'apprentissage automatique afin de faire de la prédiction sur les événements à venir, l'architecture Lambda est le meilleur choix. Maintenant que nous avons vu les différentes architectures que nous avons à notre disposition, nous allons nous intéresser aux solutions logicielles permettant de réaliser les différentes fonctions de ces architectures.

Analyse des solutions logicielles existantes

Maintenant que nous avons vu les différentes architectures Big Data existantes et que nous les avons décomposées, on va s'intéresser plus en détail à chaque composant de ces architectures. Pour chaque composant, nous allons présenter diverses solutions existantes permettant de remplir le rôle de ce dernier. Pour chacune de ces solutions, nous allons voir leurs avantages et inconvénients et leurs manières de fonctionner dans le but de pouvoir en dégager des critères de sélections.

2.1 Message Broker

Un Message broker [6], agent de message en français, est un moyen de communication utilisant des messages entre deux applications (Ex. Communication entre un serveur et un client). Un message broker permet une communication asynchrone entre applications. L'utilisation de cette solution permet de pouvoir facilement filtrer les messages que l'on reçoit et de stocker temporairement les messages reçus afin d'éviter les pertes de données. Ce dernier cas s'avère très utile dans le cas où l'application chargée de la réception des données n'est pas en fonctionnement pendant un certain temps. Il existe deux types de communications avec un message broker :

Publisher / Subscriber

Dans ce mécanisme, l'entité envoyant les données est nommée "Publisher" et l'entité les récupérant est nommée "Subscriber". Le publisher va envoyer des données dans des topics¹ Afin que les Subscribers de ce topic puissent les récupérer. Un publisher peut envoyer des données dans un ou plusieurs topics, et les subscribers peuvent être abonnés à un ou plusieurs topics (voir figure 2.1).

Point-to-point communication

La communication point à point est la forme la plus simple de Producteur/Consommateur. Le producteur envoie ses données dans une queue et le consommateur va lire les

1. Un topic est une catégorie dans laquelle les messages produits sont stockés.




Figure 2.1 – Schéma du principe Publisher(Producer)/Subscriber

messages dans la queue. Tout comme le modèle précédent, il peut y avoir plusieurs producteurs et consommateurs sur la même queue, mais si plusieurs consommateurs sont présents, ils recevront des portions différentes des messages afin de favoriser le traitement concurrentiel.

2.1.1 Kafka

Apache Kafka [7][8] est un système de messages distribué, développé par LinkedIn.

Kafka utilise le système de communication du Publisher(Producer) / Subscriber en utilisant un élément unique, appelé broker. Afin de faciliter la mise à l'échelle et le partitionnement des données, il est possible d'instancier autant de brokers que l'on souhaite afin d'augmenter le débit et la résilience du produit.

Une autre brique est utilisée par Kafka afin de gérer l'état des différents brokers, il s'agit de Apache ZooKeeper. Il permet de stocker facilement toutes les métadonnées de chaque broker, par exemple le nombre de données injectées dans chaque topic, ou bien la répartition des différents topics sur chaque broker (voir figure 2.2).

Les messages envoyés à Kafka sont stockés sur disque dans le format appelé **LOG**. Ce format n'a rien à voir avec les logs applicatifs, il s'agit d'un tableau de messages ordonnés. L'ordonnement est réalisé à partir de la date d'arrivée du message. Chaque message se voit donner un index aussi appelé offset.

2.1.2 ActiveMQ

Comme Kafka, ActiveMQ utilise le système de communication Publisher(Producer) / Subscriber. L'intérêt principal d'ActiveMQ est de connecter différentes applications réalisées avec des langages différents avec l'aide des API fournis.

De la même manière que Kafka, il permet de se mettre à l'échelle très facilement, mais il n'utilise pas de brique intermédiaire afin de gérer les états des brokers (ZooKeeper). Les différentes instances d'ActiveMQ utilisent un système de multicast afin de se découvrir.




Figure 2.2 – Schéma d'un cluster Kafka et de ces composants

2.1.3 RabbitMQ

Contrairement à Kafka et ActiveMQ, RabbitMQ utilise le système de communication Point-to-Point. Cela permet de garantir qu'un seul consommateur va être en mesure de lire le message présent dans la queue.

RabbitMQ n'utilise pas de brique extérieure afin de gérer la mise à l'échelle, mais il suit le même mode de fonctionnement que ces deux concurrents, c'est-à-dire un système de partition.

Conclusion

Nous pouvons constater que ces trois solutions se ressemblent, elles se départagent uniquement sur quelques points. L'utilisation de différents protocoles, le mécanisme de communication ou bien la manière de se mettre à l'échelle.

2.2 Ingestion/Extraction de données

La première catégorie, qui est aussi la première étape d'une architecture Big Data, c'est la récupération de données. Plus précisément comment allons-nous récupérer des données, soit via des requêtes sur des sources externes, soit des sources externes nous envoie directement des données.

Il existe deux approches afin d'effectuer cette tâche, soit l'utilisation d'un logiciel appelé ETL ou ELT ou bien l'écriture de programme. Un logiciel ETL (Extract Transform & Load) ou ELT (Extract Load & Transform) sont des solutions permettant d'extraire

des données depuis des sources, appliquer une transformation sur ces données et enfin les charger dans une solution de stockage. En plus d'être une solution complète, la gestion du flux des données est entièrement paramétrable à l'aide d'une interface graphique afin de faciliter l'utilisation de ces outils. La distinction entre ETL et ELT est l'ordre dans lequel les opérations sont effectuées, soit les données sont d'abord transformées puis stockées (ETL) soit l'inverse (ELT). Les deux premières solutions que nous allons aborder pour répondre à la problématique de l'ingestion des données sont des ETL/ELT.

2.2.1 Apache Nifi

Apache Nifi est une solution ETL/ELT open source sous la licence Apache 2.0 écrite en Java et développée par la fondation Apache.

Apache Nifi est tolérant aux pannes et peut être facilement mis à l'échelle avec l'aide de Apache Zookeeper [9]. Cela bien évidemment, implique d'avoir installé et configuré au préalable Zookeeper.

Apache Nifi possède plus de 200 connecteurs lui permettant de récupérer des données depuis différentes sources, et il se couple très bien avec Apache Kafka.

2.2.2 Talend Open Studio

Talend Open Studio est une solution open source sous la licence Apache 2 et développé par Talend.

Il y a trop peu d'informations présentes sur cette solution pour en dégager un mode de fonctionnement précis, il faudrait installer et tester en détail cette solution afin de récupérer des informations sur son fonctionnement. Ce qui malheureusement, par faute de temps n'est pas envisageable.

Conclusion

Malheureusement, n'ayant pas assez d'informations pour Talend Open Studio, on ne pourra pas effectuer de comparaison entre ces deux solutions ETL/ELT. Mais nous pourrons toujours voir en détail les critères menant à l'utilisation d'un ETL et ceux menant à l'écriture d'un programme personnalisé.

2.2.3 Solution maison

Il est aussi tout à fait possible d'envisager d'écrire un programme simple permettant d'extraire des données depuis une source pour ensuite les injecter dans une base et lancer le traitement des données. Pour nous aider dans cette tâche, il existe dans une majorité des langages des connecteurs permettant d'interagir par exemple avec des

bases de données. Toutefois, il est important de respecter certains critères avant de se lancer dans le développement d'un programme maison. Comme on l'a vu tout au long de notre recherche, l'un des points clés du Big Data est sa capacité de mise à l'échelle. Il faut donc choisir le langage ou un framework pouvant lui aussi être mis à l'échelle facilement, c'est-à-dire qu'il doit adopter une architecture réactive (A.1). Deux frameworks très connus utilisant cette architecture sont Akka et Vert.x. Akka utilise le principe de concurrence d'Acteur tandis que Vert.x utilise le principe d'évènements. Akka supporte officiellement Java et Scala et l'on peut facilement l'utiliser avec d'autres langages de la JVM². De son côté, Vert.x supporte de manière officielle Java, Scala, Kotlin, JavaScript, Ruby et Ceylon. Il existe des modules pour Vert.x permettant de supporter d'autres langages comme le python par exemple, mais ils ne sont pas maintenus par Vert.x.

Conclusion

Pour conclure sur cette partie, nous avons donc le choix d'utiliser des solutions complètes configurables facilement, ou bien écrire nous-mêmes un programme réalisant l'ingestion des données. L'utilisation d'une solution complète peut paraître la plus attractive, mais elle est plus consommatrice en ressources qu'un simple programme.

2.3 Traitement des données

Après avoir récupéré des données, nous devons passer à l'étape du traitement de celles-ci. Celui-ci a plusieurs rôles, en effet il peut servir à formater les données, leurs apporter de la cohérence en les combinant à des données déjà présentes. Et pour finir, les rediriger vers le stockage souhaité. Le traitement des données peut se faire de deux manières différentes. La première solution est le traitement par Batch, et la seconde est le traitement en temps réel [10][11]. Chacune possède ses avantages et inconvénients, nous allons voir ça plus en détail.

2.3.1 Batch

Le traitement par Batch (Traitement par lot), consiste à traiter un important volume de données à un instant T. Le traitement par batch est surtout utilisé dans les cas où nous avons des données stockées de manière journalière, et que nous avons besoin de tout traiter en fin de journée. Il n'est pas rare de voir des tâches de traitements par Batch s'exécuter dans la nuit, étant donné que l'on traite une masse de données importante, on sollicite la machine pendant une longue période. Réaliser ce traitement durant des périodes creuses, permet de largement diminuer l'impact sur l'utilisation de la plateforme (2.3).

2. Machine virtuelle java

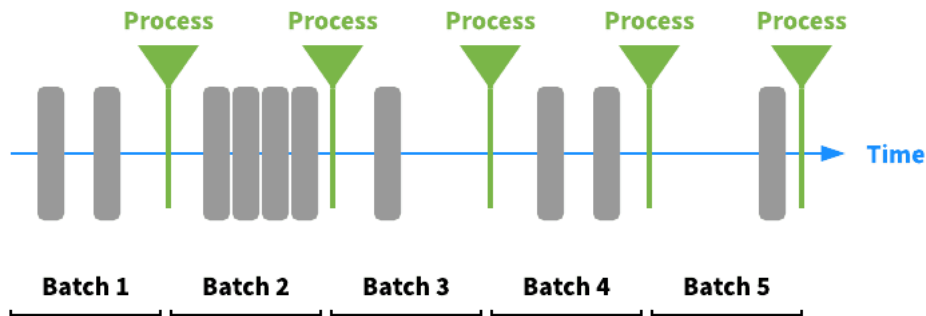


Figure 2.3 – Schéma du traitement par batch

Nous allons nous pencher sur les solutions existantes, implémentant un traitement par batch.

2.3.1.1 Apache Spark

Spark est un moteur de traitement de données distribué, il répond à de nombreux cas d'utilisation. En plus du moteur de traitement de données, Spark possède des bibliothèques SQL, d'apprentissage automatique, de calcul des graphes ainsi que le traitement de flux qui sera abordé dans la partie 2.3.2.1 sur Spark Streaming. Spark supporte différents langages de programmation, Java, Scala, Python et R.

Spark a des performances accrues, car entre chaque étape des calculs, au lieu de stocker les résultats sur disque il les garde en RAM.

2.3.1.2 Hadoop MapReduce

MapReduce est aussi un moteur de traitement de données distribué, mais il répond à de moins nombreux cas d'utilisation que son concurrent. Il ne possède qu'une seule bibliothèque permettant de faire de l'apprentissage automatique. Il manque donc de bibliothèques SQL, de calcul des graphes ainsi que de traitement de flux contrairement à son concurrent.

Au niveau des performances, MapReduce se montre moins efficace que Spark. Là où Spark va stocker en RAM tous les résultats intermédiaire, MapReduce va stocker ces résultats sur disque. Cela a un impact non négligeable sur les performances, mais il permet aussi de diminuer les coûts de la plateforme et de garantir une meilleure tolérance à la panne.

Conclusion

Ces deux solutions sont intéressantes, mais couvrent des cas d'utilisation vraiment différents. Il est donc très important de bien cibler son besoin afin de faire le bon

choix pour son architecture.

2.3.2 Streaming

Un traitement de données est considéré comme étant en temps réel s'il s'effectue en une seconde ou moins après la réception de la donnée. Il peut être de deux types, soit des micros batchs soit en streaming.

Micro-Batch

Le traitement par micro batch est basé sur le même principe que le traitement par batch, à l'exception qu'il s'exécute beaucoup plus régulièrement (toutes les secondes ou moins) et que le nombre de données à traiter est donc significativement plus faible. Le micro batch est surtout utilisé dans les cas où notre système ne peut pas directement réagir lorsqu'une donnée arrive, on va donc récupérer les données très régulièrement afin de garantir un traitement en temps réel ou du moins dans le délai le plus bref possible.

Streaming

Le traitement en streaming (Traitement de flux) s'appuie sur l'architecture réactive (A.1). En effet, contrairement aux traitements par batch et micro batch, ici on ne va pas récupérer des données de temps en temps. Dès qu'une donnée arrive, on va la récupérer et la traiter immédiatement. Par son fonctionnement, le traitement en streaming ne nécessite pas de stockage en amont contrairement aux autres types de traitement (2.4).




Figure 2.4 – Schéma du traitement en streaming

Nous allons maintenant nous intéresser aux différentes solutions proposant ce type de traitement.

2.3.2.1 Apache Spark Streaming

Spark Streaming est comme on l'a vu précédemment une version de Spark étudiée pour le traitement en temps réel. Il bénéficie donc du large choix de librairie de Spark.

Spark Streaming à une latence assez faible, mais pas suffisamment pour s'orienter vers du traitement en streaming il est plus orienté pour un traitement en micro batch.

Spark Streaming s'avère très utile dans le cadre d'une architecture Lambda, comme on l'a vu dans cette architecture les traitements en batch et en temps réel sont effectués par des outils différents. Spark Streaming permet d'avoir la même base de code pour le traitement en batch et en temps réel, cela permet d'éviter de la duplication de code et de pouvoir n'utiliser entre autres qu'un seul outil pour le traitement des données.

2.3.2.2 Apache Storm

Apache Storm propose une sélection moins importante de langage de programmation que Spark Streaming. Il ne propose que le Java, Scala et Clojure.

Contrairement à Spark Streaming, Apache Storm possède une latence beaucoup plus faible ce qui lui permet de gérer le traitement en streaming sans aucun problème.

Tout comme Spark Streaming, Apache Storm stock les résultats intermédiaires en RAM pour garantir des performances accrues.

Apache Storm ne propose pas de librairie de calcul des graphes et n'a pas de librairie d'apprentissage automatique intégré, il faudra donc en installer une compatible manuellement.

Apache Storm à l'opposé de son concurrent ne permet pas de garder la même base de code entre le traitement en batch et en streaming, son utilisation se place par conséquent plus dans le cadre d'une architecture Kappa.

Conclusion

Malgré un mode de fonctionnement similaire, ces deux solutions peuvent se démarquer sur des points importants qui nous permettront de définir des critères précis par rapport à leur utilisation.

2.4 Stockage des données

Une partie très importante du Big Data est le stockage des nombreuses données que l'ont reçoit. Il existe énormément de manières différentes de stocker des données selon la manière dont nous voulons les utiliser par la suite et surtout selon leurs formats. De plus, l'utilisation de plusieurs bases de données est très courante, généralement une base de données est utilisée pour le stockage des données brutes avant leurs traitements (appelé lac de données) puis une autre base de données correspondant au nouveau format des données est utilisée pour améliorer les performances. Le stockage des données dans le Big Data doit s'assurer de pouvoir stocker toutes les données reçues et avoir une très haute disponibilité. Pour cela de la réplication de données et une mise à l'échelle pour la lecture et l'écriture des données sont présentes.

Cela implique de s'éloigner des bases de données relationnelles et de s'orienter vers des solutions NoSQL qui facilitent la mise en place de ces concepts. Nous n'allons pas voir en détail le fonctionnement des bases de données NoSQL, nous nous contenterons de voir si les bases de données intègrent bien ces concepts et si elles ont des particularités sur la manière de traiter les données. Si vous souhaitez voir plus en détail le fonctionnement des bases de données NoSQL, je vous conseille de lire l'article de Sonia Guehis et Marta Rukoz à ce sujet [1].

2.4.1 Base de données de séries temporelles

La première catégorie de base de données que nous allons traiter est la base de données de séries temporelles. Ce type de stockage est de plus en plus important avec l'explosion de l'IoT qui est un des domaines générant le plus de données de séries temporelles.

Une série temporelle est tout simplement une valeur datée, par exemple la température d'un processeur à un instant T.

2.4.1.1 OpenTSDB

OpenTSDB est une base de données Open Source sous la licence GPL3 écrit en Java.

Afin de stocker les données, OpenTSDB se base sur une autre base de données appelée HBase, nous verrons plus en détail HBase dans la partie 2.4.6.1. Cette solution implique donc que vous avez déjà installé HBase et d'avoir les connaissances nécessaires pour le configurer correctement afin de garantir de bons débits de lecture et d'écriture.

OpenTSDB ne fournit pas d'outil de requêtage simplifié, il faut donc être familier avec HBase pour récupérer des données stockées dans OpenTSDB.

2.4.1.2 InfluxDB

InfluxDB est une solution Open Source développé par InfluxData sous la licence MIT et écrit en Go.

Contrairement à OpenTSDB, InfluxDB n'utilise pas de solution externe pour le stockage des données. Il possède sa propre solution optimisée pour les données de série temporelle. Cela à un double avantage. Premièrement, pas besoin d'installer une autre base de données et d'avoir les connaissances nécessaires pour la configurer pour des données de série temporelles. Cela permet aussi d'avoir des performances accrues, l'architecture de stockage étant créé dans le seul but de stocker des données de série temporelle, il est normal que les performances soient meilleures que pour une solution qui peut gérer plusieurs formats de données.

Par rapport à son concurrent, InfluxDB propose une solution de requêtage de données simplifiées, en utilisant le langage SQL.

Conclusion

Nous pouvons constater que InfluxDB à l'air d'être la meilleure solution pour le stockage de série temporelle, mais le fait que OpenTSDB utilise HBase peut être un critère de choix pour certaines personnes pour le choix de leur architecture.

2.4.2 Base de données orientée graphe

Les bases de données orientées graphe sont apparues afin de permettre de stocker facilement les relations présentes entre plusieurs données. Une base de données orientée graphe est basée sur les bases de données orientées objet, mais avec l'utilisation de la théorie des graphes. Le stockage des données est constitué de nœuds qui représentent les données et d'arcs qui sont des pointeurs physiques représentant les relations entre chaque nœud. Ce type de bases de données s'avère très utile dans le cadre des études des relations entre de nombreuses de données, ce qui souvent le cas dans le domaine du Big Data. La figure 2.5 montre un exemple de graphe qui peut être stocké dans une base de données orientée graph.

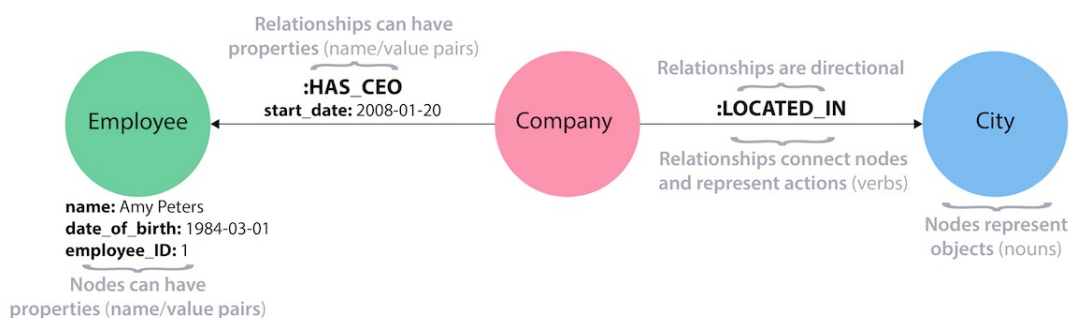


Figure 2.5 – Exemple d'un graphe dans une base de données orientée graphe

Source : <https://neo4j.com/developer/graph-database/>

2.4.2.1 Neo4j

Neo4J est une base de données orientée graphe native écrite en Java et créée par l'entreprise portant le même nom. Il existe deux versions de Neo4J, une version communautaire qui est open source sous la licence GPL3 et une version entreprise qui elle n'est pas open source. La solution communautaire manque de module de sécurité et ne propose pas de solution de mise à l'échelle.

Neo4J propose une longue liste de langage compatible .Net, Clojure, Elixir, Go, Groovy, Haskell, Java, JavaScript, Perl, PHP, Python, Ruby et Scala.

Un atout de Neo4J est que c'est une solution native, cela permet une installation rapide et aucune dépendance nécessaire. Neo4J propose une interface web intégrée pour la visualisation des graphes ainsi que pour l'écriture de requête avec leur propre langage nommé Cypher. Voici un exemple de requête utilisant le langage Cypher :

```
(p:Person {name: "Jennifer"})-[rel:LIKES]->(g:Technology {type: "Graphs"})
```

Cette requête permet de récupérer la relation qui représente le fait que Jennifer aime la technologie.

Neo4J propose une mise à l'échelle pour la lecture ce qui la rend très rapide, malheureusement l'écriture n'est pas mise à l'échelle. Les performances en écriture restent très performantes, mais l'insertion d'énormément de données sur une longue période peut s'avérer assez lente.

2.4.2.2 JanusGraph

JanusGraph est une solution open source sous la licence Apache 2 écrite en Java.

Contrairement à Neo4J, la liste de langage supporté par Janusgraph est beaucoup moins importante. Il ne supporte que le Java, Python et Clojure.

JanusGraph n'est pas une solution native, il s'appuie sur Hbase (voir partie 2.4.6.1) ou Cassandra (voir partie 2.4.6.2) pour le stockage des données et pour l'indexation il est fortement recommandé d'utiliser Elasticsearch (voir partie 2.4.4.1) ou Solr (voir partie 2.4.4.2) qui sont des moteurs d'indexation. Cela implique donc qu'il est nécessaire d'avoir à disposition ces solutions et de les maîtriser afin de permettre leurs communications.

JanusGraph ne possède pas d'interface web, mais comme il s'appuie sur une solution de requêtage open source, cela lui permet de bénéficier d'interface web déjà développée. L'interface web la plus intéressante est Linkurious.

Le langage de requêtage utilisé par JanusGraph est Gremlin, il est aussi facile à utiliser que Cypher, mais les requêtes ne sont pas formées de la même manière. Voici un exemple de requête avec le langage Gremlin :

```
g.V().has('name', 'hercules').out('father').out('father').values('name')
```

Cette requête permet de récupérer le nom du grand père du nœud ayant comme nom Hercules.

JanusGraph propose lui aussi une mise à l'échelle pour la lecture des données et avec des performances similaire par rapport à son concurrent. Mais il ne s'arrête pas là, grâce à son utilisation de brique extérieure (HBase ou Cassandra), il propose aussi une mise à l'échelle pour l'écriture des données.

Conclusion

Nous pouvons constater que sur les deux solutions que nous avons étudiées, la différence majeure réside sur le fait que Neo4J est une solution native tandis que Janus-Graph s'appuie sur des technologies déjà existantes.

2.4.3 Base de données clés/valeurs

Les bases de données clés / valeurs se reposent sur une structure très basique, qui est probablement la structure de données la plus simple. Le principe repose sur le fait qu'on peut y stocker uniquement des paires de clés et de valeurs. La récupération des valeurs s'effectue via une clé connue. Ce système de stockage ressemble au HashMap que l'on peut utiliser dans différents langages. Au-delà de ce principe de paires, il n'y a aucune structure des données, cela permet de pouvoir stocker n'importe quelle donnée sans avoir à définir un schéma à respecter et donc de réduire l'espace nécessaire.

Ce système de stockage étant trop simple pour répondre aux besoins d'application complexes, il trouve néanmoins son intérêt dans le cadre de système embarqué ou bien s'il y a un besoin de traitement de données à très haute performance.

2.4.3.1 Redis

Redis est développé par Redis Lab et écrit en C, il est open source sous la licence BSD.

Redis propose un support d'un très grand nombre de langages de programmation, il en propose plus de 20 dont par exemple Java, Python, C++ et Go.

Redis opère principalement sur la mémoire RAM pour garantir la vitesse la plus élevée possible. Il propose tout de même une solution de "persistance" via des snapshots effectués régulièrement. Les snapshots sont des sauvegardes de ce qui est stocké sur la RAM à un instant T.

Redis propose également un cluster, permettant de répartir la charge sur différents nœuds. Ainsi qu'une réplication des données.

2.4.3.2 RocksDB

RocksDB est une solution open source sous les licences GPLv2 et Apache 2, il est écrit en C++ et développé par Facebook.

Contrairement à Redis, RocksDB supporte beaucoup moins de langage, il ne propose le support que pour Java et C++.

À l'opposé de Redis, RocksDB opère principalement sur disque, ce qui permet de rendre les données persistantes à tout moment et de pouvoir interagir avec des données plus volumineuses. Afin de pallier le manque de vitesse par rapport à son concurrent qui utilise la RAM, RocksDB profite du stockage flash apporté par les nouveaux SSD proposant des débits de plus en plus rapides.

Tandis que Redis est une solution accessible par différentes applications sur le réseau, RocksDB lui est une solution embarquée sur un appareil, il est accessible uniquement sur la machine sur laquelle il est installé. Cela limite donc les possibilités de mise à l'échelle, mais permet de réduire les interactions sur le stockage.

Conclusion

Nous pouvons constater que ces deux solutions de stockage basé sur le modèle clé/valeur sont complètement opposées. Cela va nous permettre de facilement dégager des critères pour définir les situations correspondants le mieux à chacun de ces outils.

2.4.4 Moteur d'indexation

Les moteurs d'indexation sont une catégorie de bases de données qui en général ne servent pas de stockage permanent, mais d'outil intermédiaire pour la visualisation et l'analyse des données. Le principe de cette solution est d'indexer toutes les données afin de permettre des requêtes beaucoup plus rapides, spécialement pour des opérations de recherche. Il est en effet beaucoup plus rapide de rechercher une donnée avec un catalogue qu'en parcourant toutes les données stockées. Cela permet de faire des recherches plus avancées sur les données tout en pouvant facilement mettre à l'échelle l'exécution des recherches et le stockage des données. Afin de stocker des données dans ce genre de base de données, il suffit de créer un index pour un jeu de données en définissant le type de nos champs. Une fois cela fait, au moment d'injection des données dans la base de données, il suffit de spécifier l'index à utiliser. Ensuite, les données seront indexées en fonction des paramètres présents dans l'index, cette opération peut prendre un peu de temps, mais une fois effectué, les recherches seront très rapides.

2.4.4.1 Elasticsearch

Elasticsearch est une solution open source sous la licence Apache 2 écrite en Java par l'entreprise Elastic.

Le moteur de recherche utilisé par Elasticsearch est Apache Lucene.

Elasticsearch est une solution native, c'est-à-dire qu'il ne nécessite aucune installation de dépendances et que tous ses composants ont été conçus dans le but de créer un moteur d'indexation. Elasticsearch possède un mécanisme de mise à l'échelle. Par son indexation "strict", Elasticsearch permet un traitement de données structuré en

temps réel. Il propose aussi une intégration de module d'apprentissage automatique permettant la détection d'anomalies en temps réel.

Elasticsearch fait parti de la suite elastic qui propose aussi un outil d'analyse et de visualisation des données nommées Kibana (voir partie 2.6.1). Kibana et Elasticsearch sont entièrement compatibles, plus précisément Kibana s'intègre uniquement avec Elasticsearch.

2.4.4.2 Apache Solr

Apache Solr est une solution open source sous la licence Apache 2 écrite en Java par la fondation Apache.

Solr est très similaire à Elasticsearch en termes de performances malgré une architecture vraiment différente. En effet, Solr s'appuie sur plusieurs dépendances afin de proposer une solution complète contrairement à Elasticsearch qui lui ne nécessite aucune brique extérieure. Le seul point commun avec Elasticsearch est que Solr aussi utilise Apache Lucene. Pour le stockage des données, l'utilisation d'Hadoop HDFS (voir partie 2.4.7.1) est requise. Solr lui aussi dispose d'une solution de mise à l'échelle, mais cela nécessite d'installer Zookeeper. Solr fournit aussi un module d'apprentissage automatique, mais celui-ci est orienté pour la compréhension du langage naturel. Le mode de fonctionnement de l'indexation de Solr lui permet de traiter des données moins structurées qu'Elasticsearch, mais il supporte moins bien les traitements en temps réel.

Apache Solr dispose lui aussi de son outil de visualisation et d'analyse de données dédiées, il s'agit de Banana (voir partie 2.6.2).

Conclusion

Malgré une base commune entre ces deux solutions, leurs utilisations diffèrent par les différences dans leur architecture.

2.4.5 Base de données orientée documents

Les bases de données orientées documents sont une forme avancée du stockage clé/valeur. Ces bases de données ont la particularité d'avoir une organisation des données sans schéma. Cela implique que :

- Les enregistrements peuvent avoir des colonnes différentes.
- Le type des valeurs associées à chaque colonne peut être différent.
- Les colonnes peuvent avoir plus d'une valeur (tableaux).
- Les enregistrements peuvent avoir une structure imbriquée.

Les bases de données orientées documents utilisent le format JSON ou XML pour le stockage des données. Le format JSON étant moins lourd est celui qui est de plus en plus privilégié pour ce genre de base de données.

2.4.5.1 CouchDB

2.4.5.2 CouchBase

2.4.5.3 MongoDB

2.4.6 Base de données à grandes colonnes

Une base de données à grandes colonnes permet de stocker des enregistrements avec la capacité de contenir un très grand nombre de colonnes dynamiques. Les noms des colonnes ainsi que les clés des enregistrements n'étant pas fixés, un enregistrement peut contenir énormément de colonnes. Par ce mode de fonctionnement, les bases de données à grandes colonnes sont souvent considérées comme des bases de données clé/valeur bidimensionnelles.

2.4.6.1 HBase

Disponibilité, need HDFS, meilleur lecture

La figure 2.6 représente un exemple de la manière dont sont stocker les données dans HBase.

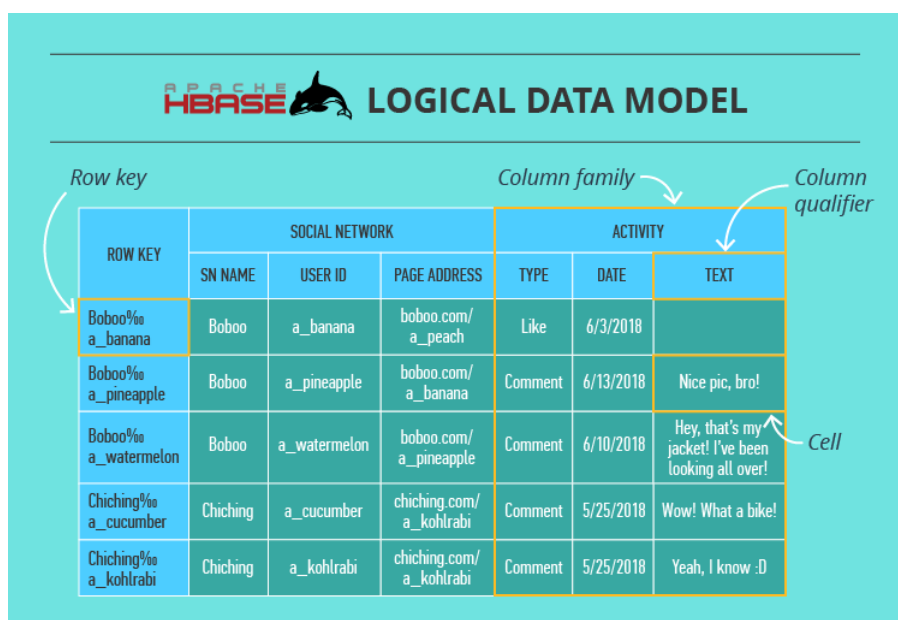


Figure 2.6 – Schéma du principe de stockage de cassandra

Source : <http://www.alliedc.com/apache-cassandra-database-4-problems-that-cassandra-developers-administrators-face/>

2.4.6.2 Cassandra

Consistent, meilleur en écriture, solution native

La figure 2.7 représente un exemple de la manière dont sont stocker les données dans Cassandra.

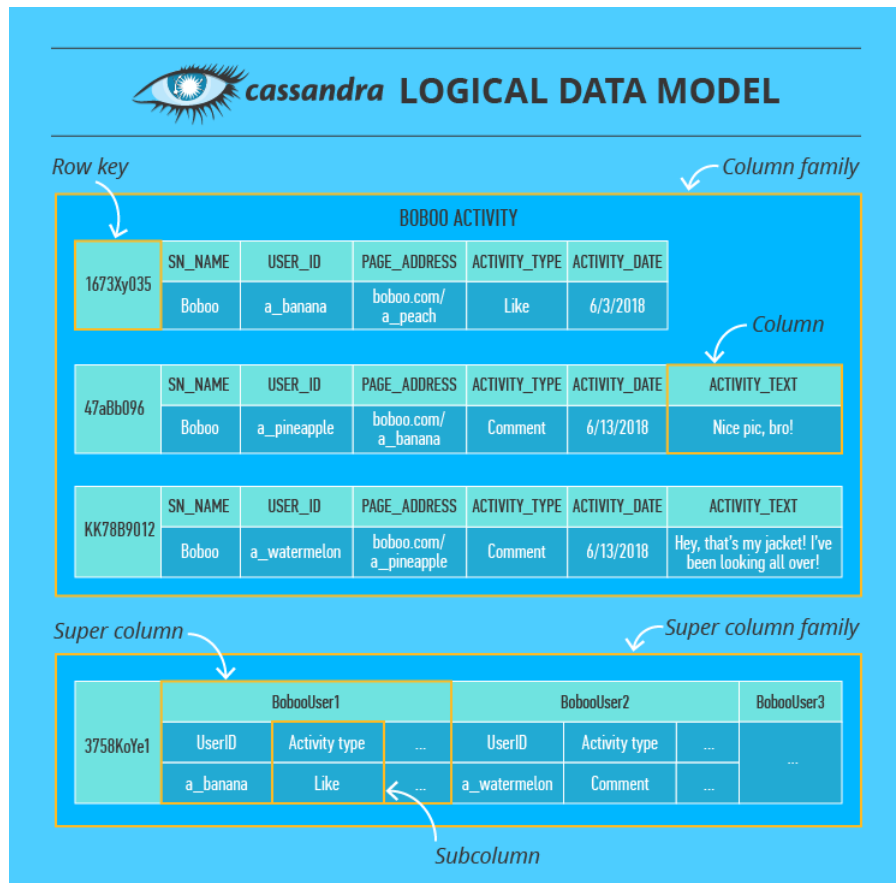


Figure 2.7 – Schéma du principe de stockage de cassandra

Source : <http://www.alliedc.com/apache-cassandra-database-4-problems-that-cassandra-developers-administrators-face/>

2.4.7 Système de fichiers

Les bases de données de système de fichier sont des bases de données qui reprennent le principe de système de fichier classique en y apportant quelques modifications. La principale modification apportée est la mise à l'échelle du système de fichier.

2.4.7.1 Hadoop HDFS

Hadoop HDFS est une solution open source sous la licence Apache 2 écrite en Java et développée par la fondation Apache.

HDFS permet le stockage d'un fichier réparti sur plusieurs machines. Dans celui-ci, les fichiers sont divisés en blocs, généralement de 64 ou 128Mb. Une des particularités de HDFS est que les fichiers sont écrits une seule fois, et s'ils sont amenés à être modifiés, ils doivent être réécrits entièrement.

HDFS se compose de deux processus : un namenode et de multiples datanodes. Les datanodes sont le lieu de stockage des blocs, tandis que le namenode a pour rôle de sauvegarder l'arborescence des informations, soit l'emplacement des blocs et les autorisations d'accès pour chaque fichier. Le namenode quant à lui, est un point individuel de défaillance, c'est-à-dire que le système entier repose sur cette instance et qu'en cas de panne de celle-ci, HDFS n'est plus accessible. Un second namenode peut tout de même être mis en place afin de garder une sauvegarde des métadonnées en cas de panne sévère.

2.5 Requêtage des données

Afin de permettre l'analyse et la visualisation des données, il est nécessaire de requêter les données stockées dans des bases de données. Pour cela il y a deux possibilités. La première solution est d'utiliser les outils de requêtage fournis par les bases de données, et la seconde est d'utiliser des bibliothèques externes permettant d'uniformiser le requêtage entre les différentes bases de données.

Aujourd'hui, les solutions de stockage proposent des solutions de requêtage qui essaient d'être le plus simple possible tout en conservant des performances suffisantes. L'utilisation de bibliothèque externe est surtout utile si vous ne souhaitez pas apprendre les requêtes pour chacune des bases de données que vous utilisez. Étant donné que ces solutions de requêtage ne sont pas primordiales et que ce mémoire traite déjà de beaucoup de technologies, nous n'allons pas nous intéresser à ces solutions. Je voulais juste préciser que de telles solutions existaient, et je vous laisse vous renseigner si cela vous intéresse.

2.6 Visualisation et Analyse des données

2.6.1 Kibana

Kibana est une solution open source sous la licence Apache 2 écrite en JavaScript et développée par Elastic.

Kibana fait partie de la suite Elastic, il est conçu spécialement pour permettre de faire la visualisation et l'analyse des données stockées sur Elasticsearch.

Elasticsearch propose la création de Dashboard qui sont constitués de visualisations. Kibana propose plusieurs types de visualisations, les classiques graphes linéaires, camembert etc. Il propose également des visualisations géographiques, des interfaces de séries temporelles, un module d'étude de graph et pour finir de l'apprentissage automatique pour faire de la détection d'anomalies en temps réel.

2.6.2 Banana

Banana est une solution open source sous la licence Apache 2 écrit JavaScript et développé par lucidworks.

Banana est une solution d'analyse et de visualisation de données spécialement conçu pour fonctionner avec Apache Solr. Banana ressemble énormément à Kibana étant donné que c'est un fork de Kibana adapté pour fonctionner avec Apache Solr. Les seules différences avec Kibana sont dans la différence de direction évoqués lors de la présentation d'Apache Solr.

2.6.3 Grafana

Grafana est une solution de visualisation et d'analyse de données open source sous la licence Apache 2 écrit en Go et développé par Grafana Lab.

Grafana est spécialisé dans les données de séries temporelles afin de faire du monitoring. Il permet de récupérer de données depuis Elasticsearch et depuis les différentes bases de données de séries temporelles.

2.6.4 D3.js

D3.js est une solution de visualisation et d'analyse des données open source sous la licence BSD écrit en JavaScript et développé par Mike Bostock.

D3.js est l'une des solutions d'analyse et de visualisation des données la plus complète à ce jour. Cet outil permet de faire pratiquement n'importe quel type de visualisation, sa seule limite est sa complexité. En effet, contrairement aux trois autres solutions, D3.js ne propose pas d'interface graphique pour la réalisation des visualisation, tout se fait en ligne de code JavaScript. Son avantage est qu'il peut récupérer des sources de données en json ou csv, donc si vous pouvez facilement récupérer vos données avec ce format vous pourrez utiliser D3.js pour faire vos visualisations.

Conclusion

Le domaine de la visualisation et analyse de données est très vaste, nous nous sommes intéressé qu'au solution les plus répandu, mais cela permet déjà de couvrir un maximum de cas d'utilisation.

2.7 Orchestration

Les solutions Big Data ont besoin d'un moyen de programmer l'exécution de certaines tâches, par exemple l'exécution de l'ingestion des données d'une source de données

ou bien la création d'un rapport sur un outil d'analyse. C'est pour cela que l'on utilise un orchestrateur.

2.7.1 Apache Oozie

Apache Oozie est une solution open source sous la licence Apache 2 écrit en Java et développé par Apache.

Apache Oozie est conçu pour fonctionner avec les outils Hadoop (MapReduce et HDFS par exemple), mais il dispose aussi de fonctionnalités pour programmer l'exécution de script Shell ou Java.

Oozie permet de définir une chaîne d'actions à effectuer à un moment précis, il permet aussi d'effectuer une autre action si jamais une des tâches de la chaîne échoue. Afin de paramétrer cette chaîne d'action, Oozie propose aux utilisateurs une interface graphique pour faciliter sa configuration.

Permet de faire des chaînes d'actions. Interface graphique.

2.7.2 Cron

Une solution beaucoup plus basique et qui existe depuis longtemps, est l'utilisation de la cron tab sous Linux. Cette solution propose uniquement de lancer une tâche tout les x temps, mais avec l'utilisation des messages broker, il n'est pas forcément nécessaire de lancer une suite de tâche. En effet, si les messages brokers permettent de déclencher des événements afin de récupérer les données, les envoyer au logiciel de traitement de données puis les stocker dans la base de données sélectionnée, la seule tâche restante est la génération d'un rapport. L'utilisation de la cron tab est suffisante pour ce genre de tâche et ne nécessite aucune installation, car elle est installée avec Linux.

2.7.2.1 Conclusion

Nous pouvons constater que la partie orchestration ne nécessite pas d'avoir une solution très avancée, même des solution basiques suffisent. Mais si l'on veut pouvoir facilement configurer l'exécution de nos tâches des solutions graphique sont tout de même à notre disposition.

Critères d'analyse

Maintenant que nous sommes familiers avec les architectures Big Data ainsi qu'avec les différentes solutions logicielles, nous allons pouvoir définir des critères afin de sélectionner l'architecture qui correspond à notre besoin. Certains critères ont déjà été dégagés au fil de ce mémoire. La première étape va être de définir des critères par rapport au choix de l'architecture et ensuite des critères pour choisir les solutions logicielles à utiliser au sein de cette architecture. En plus des différentes informations que nous avons exposées jusqu'ici, nous aurons besoin de prendre en compte le cas d'utilisation nécessitant le déploiement d'une architecture Big Data. Il est fortement possible que plusieurs critères correspondent au cas d'utilisation que vous souhaitez mettre en œuvre, et qu'ils sonnent des solutions différentes. Dans ce cas, ce sera à vous par rapport à vos ressources de définir lequel de ces critères est le plus important pour faire votre choix. Dans un premier temps, nous allons nous intéresser ce la manière dont les entreprises effectuent leurs choix d'architecture.

3.1 Sélection d'architecture en entreprise

Cette partie sera entièrement basé sur mon expérience professionnel, je ne peux en aucun cas garantir que la sélection d'une architecture s'effectue de la même manière dans toutes les entreprises.

De ce que j'ai pu voir jusqu'à aujourd'hui, les entreprise ne s'intéressent pas aux architectures existantes pour le choix de leur architecture. En effet, elle ne vont pas regarder quelles sont les différences entre l'architecture Kappa et l'architecture Lambda afin de savoir vers laquelle ils vont s'orienter. Les entreprises vont s'intéresser directement aux solutions logicielles, et vont de ce fait concevoir eux même leur propre architecture. Bien évidemment, l'architecture qui sera issue des choix de l'entreprise ressemblera énormément à l'architecture Kappa ou Lambda étant donné que ces deux architectures représente les deux moyens existant actuellement pour répondre aux besoins du Big Data.

Afin de choisir leurs solutions logicielles, les entreprises vont définir leur cas d'utilisation, c'est à dire ce pourquoi ils veulent constituer une architecture Big Data. La définition du cas d'utilisation de l'entreprise passe des sources de données qu'elles vont exploiter jusqu'au visualisation et analyse qu'elles souhaitent réaliser. Les entreprises vont ensuite représenter sous forme de schéma le flux que les données vont parcourir avant d'être stockées pour l'analyse, et définir les types de traitements qu'elle devront

subir. Cela permettra de sélectionner les outils de traitements et de stockage adaptés. Une fois leur cas d'utilisation et la définition de leur flux de données bien défini, ils vont pouvoir passer à la sélection des solutions logicielles. J'ai pu constater trois manières différentes que les entreprises utilisent pour effectuer leur choix.

La solution la plus simple pour une entreprise, est de fournir les informations de son cas d'utilisation ainsi que son flux de données à une autre entreprise spécialisée qui propose des architectures complètes. Une entreprise très connue dans ce domaine est HortonWorks. Ces entreprises se spécialisent dans certains cas d'utilisation et vont sélectionner les solutions logicielles adaptées à ces cas d'utilisation. Faire appel à des entreprises spécialisées est la solution la plus simple, surtout lorsque l'entreprise faisant appel à ce service ne possède pas les connaissances en interne pour le choix et l'installation d'une architecture Big Data. Par contre ce genre de solution peut être très coûteuse, spécialement si c'est l'entreprise externe qui réalise l'installation et la maintenance de l'architecture.

La seconde solution utilisée par les entreprises quand elles ne souhaitent pas faire appel à une entreprise externe, est de choisir leurs solutions logicielles en installant celles utilisées par les entreprises externes. Par exemple imaginons que les entreprises spécialisées dans les architectures Big Data utilisent souvent HBase pour le stockage des données, alors l'entreprise va elle aussi utiliser HBase pour le stockage des données. Cette solution peut s'avérer payante dans certains cas, si le cas d'utilisation de l'entreprise correspond à l'utilisation de cette technologie. Par contre si ce n'est pas le cas, toute l'architecture constituée par l'entreprise ne sera pas optimale et parfois même pas du tout adaptée.

La dernière solution, est celle que j'ai effectué tout au long de ce mémoire, c'est à dire se renseigner sur chaque solutions logicielles pouvant répondre à leurs besoins, regarder leurs fonctionnements afin de sélectionner les solutions les plus pertinentes par rapport à leur cas d'utilisation. Une fois avoir réduit le nombre de solutions à leur disposition, généralement les entreprises vont essayer de mettre en place les solutions logicielles qu'elles ont sélectionnées afin de faire des benchmarks pour leur permettre de faire le choix finale.

3.2 Critères pour le choix de l'architecture

Avant de voir les différents critères par rapport au choix de l'architecture, je tiens à rappeler ce qui a été expliqué lors de l'introduction de ce mémoire, c'est qu'avant de passer sur une architecture Big Data il faut s'assurer d'en avoir l'utilité.

Nous allons exposer les critères ainsi que leur solution adaptée sous la forme d'un tableau afin de permettre une visualisation simple pour effectuer notre choix.

Pour le dernier critère, à savoir le stockage permanent des données batch avant leur traitement, si l'on suit scrupuleusement les architectures Lambda et Kappa, la solution choisie devrait être Lambda. Mais si notre cas d'utilisation correspond en tout point à une architecture Kappa et que l'on souhaite juste avoir une partir de stockage des

Critère	Architecture
Prédiction d'évènement entrant à l'aide de modèle d'apprentissage automatique	Lambda
Traitement des données en temps réel et par lots radicalement différents	Lambda
Traitement des données par lots complexe	Lambda
Très faible latence entre récupération et affichage des données	Kappa
Traitement des données par lots et en temps réel similaires	Kappa
Stockage permanent des données batch avant le traitement	Lambda/Kappa

Table 3.1 – Table des critères pour le choix de l'architecture

données brutes, il est plus intéressant de conserver l'architecture Kappa qui est moins complexes et juste rajouter une base de données capable de stocker ces valeurs.

3.3 Critères pour le choix des solutions logicielles

Nous allons maintenant nous attaquer aux critères permettant de départager les solutions logicielles que nous avons parcouru au long de ce mémoire. Pour cela nous allons procéder comme pour la partie précédente, c'est à dire définir des critères pour chaque catégorie de l'architecture. Bien évidemment, il sera préciser pour les parties non communes aux architectures Lambda et Kappa si cette catégorie ou tel outil est fait pour l'architecture Lambda ou Kappa pour que les choix restent cohérents.

3.3.1 Ingestion des données

Pour la partie s'occupant de l'ingestion des données, nous avons pu constater qu'un premier choix s'offrait à nous. Soit une solution complète (ETL/ELT), ou bien la réalisation d'un programme suivant l'architecture réactive. Nous allons présenter toujours sous la forme de tableau les critères permettant de définir quand utiliser ces solutions.

Comme on peut le constater, les critères de choix entre l'utilisation d'une solution complète et d'un programme personnalisé sont surtout par rapport à un problème de connaissance et de complexité de maintenance. En effet, si vous devez gérer l'extraction d'un grand nombre de sources de données, il sera plus facile de les gérer via un ETL/ELT qui mets à votre disposition une interface graphique. Interface graphique qui permet même à des personnes n'ayant pas de connaissances avancées dans la programmation de pouvoir mettre en place l'extraction des données. Tandis que le développement d'un programme personnalisé, est intéressant dans le cas où vous avez les connaissances nécessaires pour le mettre en place et que vous avez besoin de performances élevées ainsi qu'une consommation de ressources moins élevée qu'un

Critère	Solution
Manque de connaissances pour la réalisation de programmes personnalisés	ETL/ELT
Nécessité d'extraire de nombreuses sources de données	ETL/ELT
Peu de sources de données	Programme personnalisé
Nécessite d'avoir des performances élevés	Programme personnalisé

Table 3.2 – Table des critères pour le choix entre une solution complète ou d'un programme personnalisé pour l'ingestion des données.

ETL/ELT. Cela permet d'avoir d'avoir un plus petit nombre de machine et/ou moins de machine ce qui engendre un coût en matériel amoindri.

3.3.2 Message Broker

Nous avons vu trois solutions pouvant être utilisées comme agent de message, à savoir Kafka, ActiveMQ et RabbitMQ. Voici le tableau des critères permettant de les départager.

Critère	Solution
Garantir la consommation d'un message par un seul consommateur	RabbitMQ
Nécessité d'ingérer rapidement une grande quantité de messages	Kafka
Ordre des messages primordial	Kafka
Nécessité de conserver les message à plus au moins long terme	Kafka
Utilisation de protocoles spécifiques (MQTT, AMQP, ...)	RabbitMQ / ActiveMQ
Règles de routage des messages complexe	RabbitMQ / ActiveMQ

Table 3.3 – Table des critères pour le choix du logicielle d'agent de messages

Comme on peut le constater, Kafka se démarque complètement de ses deux concurrents avec des cas d'utilisation bien précis. Par contre ActiveMQ et RabbitMQ ne se démarquent pas du tout entre eux. En effet à part leur méthode de communication, ils répondent aux même besoins. Afin de les départager la solution serai de réaliser un benchmarks par rapport à votre cas d'utilisation.

3.3.3 Traitement des données

Comme on l'a vu précédemment, il existe deux types de traitement de données, le traitement par lots et le traitement en temps réel. Pour choisir lequel de ces deux traitements correspond à votre cas d'utilisation, il suffit de voir quel architecture correspondait à vos critères dans la partie précédente. Si c'était l'architecture Kappa, vous aurez uniquement besoin d'une solution de traitement en temps réel, dans le cas contraire vous aurez besoin d'intégrer les deux types de traitements de données.

3.3.3.1 Traitement par lots

Regardons maintenant comment départager les deux solutions de traitement pas lots que nous avons étudié.

Critère	Solution
Nécessité d'utiliser des librairies autres que le machine learning	Spark
Nécessité d'avoir des performances accrues	Spark
Nécessité d'avoir une tolérance à la panne exemplaire	MapReduce
Les performances ne sont pas la priorité	MapReduce

Table 3.4 – Table des critères pour le choix de la solution de traitement par lots.

Spark est une solution qui va convenir dans le cadre où des performances maximales sont nécessaires. Si jamais vous utilisiez une architecture Kappa, l'utilisation de Spark peut être intéressante sur vous utilisez son petit frère pour le traitement de données en temps réel, cela vous permettra de garder une base de code commune entre vos différents traitements. MapReduce lui est intéressant dans le cas où vous n'avez pas spécialement besoin de performances accrues et que vous préférez une solution moins complexe à mettre en place.

3.3.3.2 Traitement en temps réel

Le tableau 3.5 présente les critères permettant de départager les deux solutions de traitements en temps réel que nous avons étudié, c'est à dire Apache Spark Streaming et Apache Storm.

Critère	Solution
Source de données en micro batch	Spark Streaming
Source de données en streaming	Apache Storm

Table 3.5 – Table des critères pour le choix de la solution de traitement par lots.

Le choix entre ces deux solutions s'avère être assez évident. Néanmoins, si pour vous les langages mis à disposition par l'une des solutions ne vous convient pas, vous pouvez aisément vous tourner vers l'autre solution. Un autre critère à prendre en compte,

que vous utilisiez une architecture Kappa ou Lambda, l'utilisation de Spark vous permettra d'avoir une base de code similaire entre vos traitements par lots et vos traitements en temps réel.

3.3.4 Stockage des données

Comme nous avons pu le constater, il existe de nombreuses base données dans le domaine du Big Data, chacune ayant une manière différente de stocker les données. Le choix du type de base de données à utiliser va se faire par rapport aux formats des données qu'on l'on souhaite stocker et/ou l'utilisation que l'on souhaite faire de ces données. Le tableau 3.6 détails les différents critères permettant de choisir le type de base de données à utiliser.

Critère	Solution
Source de données en micro batch	Spark Streaming
Source de données en streaming	Apache Storm

Table 3.6 – Table des critères pour le choix de la solution de traitement par lots.

3.3.4.1 Base de données de séries temporelles

3.3.4.2 Base de données orientée graphe

3.3.4.3 Base de données clés/valeurs

3.3.4.4 Moteur d'indexation

3.3.4.5 Base de données documents

3.3.4.6 Base de données à grande colonne

3.3.5 Orchestration

3.3.6 Visualisation et Analyse des données

3.4 Pour aller plus loin

Dans ce mémoire nous nous sommes intéresser à une très grande partie du Big Data, nous n'avons donc pas pu étudier de manière approfondit chacune des parties constituant une architecture Big Data. De ce fait, il y a moyen d'aller plus loin dans l'étude des solutions à notre disposition.

La première manière de permettre un choix plus précis de solution, serait de prendre en compte plus de solution logicielles pour chaque catégorie de l'architecture. En effet, tout au long de ce mémoire, pour chaque catégorie je n'ai traité que deux à trois solutions, en essayant de sélectionner celles qui étaient les plus matures et les plus intéressantes. Mais en prenant en compte plus de solutions logicielles, il serait possible de rencontrer des solutions logicielles vraiment différentes et couvrant de manière native encore plus de cas d'utilisation. Malheureusement, ce mémoire n'étant pas centré sur une seule partie du Big Data, il n'était pas possible de traiter autant de possibilités.

La deuxième manière d'aller plus loin dans cet objectif de choisir l'architecture Big Data, serait de réaliser des benchmarks pour chaque solution logicielle présentée. Le fait de s'intéresser au fonctionnement de chacune des solutions étudiées n'est pas forcément suffisant pour garantir que c'est le meilleur choix par rapport à un cas d'utilisation. Afin d'avoir des tests complets, il faudrait utiliser plusieurs sources de données différentes pour les benchmarks, cela permettrait de se rendre compte facilement des différences de performances des outils en fonction des types des sources de données. Plus spécifiquement pour la partie traitement des données, il aura fallu faire des benchmarks pour plusieurs types de traitements de données afin de couvrir encore plus de cas d'utilisation et d'assurer la solution la plus optimale possible.

Comment évaluer l'architecture résultant de l'application des critères

Maintenant que nous avons réussi à définir des critères de choix pour notre architecture Big Data, il reste encore une étape pour s'assurer que les critères que nous avons définis sont corrects. Pour cela, il va falloir tester notre démarche en s'appuyant sur des cas d'utilisations réels.

4.1 Application des critères définis sur des cas d'utilisations réels

Dans un premier temps, il faut appliquer notre démarche à des cas d'utilisations réels. Pour cela, nous allons détailler les types de sources de données qui correspondent au cas d'utilisation que nous avons choisi, le type de traitement nécessaire sur ces données ainsi que la valeur que l'on veut dégager à l'aide de nos analyses sur ces données. Une fois cela fait, nous allons nous appuyer sur les critères réalisés lors de la partie précédente et lister les solutions logicielles qui ont été retenues. Une fois cette étape terminée, nous allons traiter un par un chaque cas d'utilisation. Pour chacun de ces cas d'utilisation, nous allons mettre en place les solutions logicielles issues de nos critères, ce qui nous permettra de tester notre solution dans des conditions réelles.

4.2 Évaluation des résultats

Une fois la mise en place de notre solution, afin de pouvoir mesurer son efficacité, il faudra réaliser des benchmarks et laisser la solution en place pendant quelques heures. Pendant que les données arriveront dans notre architecture, nous pourrons nous concentrer sur la réalisation des visualisations et des analyses à effectuer sur les données. Cela permettra de vérifier si la solution sélectionnée nous permet bien de réaliser sans encombre la mise en valeur que le cas d'utilisation nécessitait. En plus des résultats des benchmarks et de la réussite à faire les analyses nécessaires, il faudra aussi évaluer si tout le chemin de la donnée a bien été parcouru sans souci. Par exemple est-ce qu'il n'a pas fallu faire du développement spécifique qui n'était pas prévu pour permettre la communication entre plusieurs briques, ou bien pour effectuer le traitement des données ou encore pour le stockage des données ? Maintenant

que nous avons pu nous rendre compte de la performance de cette solution, nous allons mettre d'autres architectures avec d'autres solutions logicielles et essayer d'y appliquer le même cas d'utilisation. Nous effectuerons les mêmes tests, et à la fin nous pourrons donc facilement voir si l'architecture émise par l'application de nos critères était celle qui s'adapte le mieux au cas d'utilisation. Ensuite, nous répéterons ces étapes pour tous les autres cas d'utilisation sélectionnés pour vérifier que pour chacun d'entre eux, nos critères avaient dégagé la meilleure architecture.

Conclusion

Les différents concepts du Big Data

A.1 Architecture Réactive

Le nombre de données augmentant très rapidement et les clients demandant un service le plus rapide possible et disponible à tout moment, il est de ce fait important d'avoir une infrastructure facilement adaptable à ce flux. C'est le but de l'architecture réactive [12]. Elle repose sur quatre principes :




Figure A.1 – Schéma de l'architecture réactive

- Responsive : C'est l'objectif à atteindre.
- Scalable et Resilient : L'objectif ne peut pas être atteint sans remplir ces deux conditions.
- Message Driven : C'est la base qui permettra d'accueillir tous les composants afin d'obtenir une architecture réactive

Responsive : Un système responsive doit être en mesure de réagir rapidement à toutes les requêtes peu importe les circonstances, dans le but de toujours fournir une expérience utilisateur positive. La clé afin de proposer ce service, est d'avoir un système élastique et résilient, les architecture "Message Driven" fournissent les bases pour un système réactif. L'architecture Message Driven est aussi important pour avoir un système responsive, parce que le monde fonctionne de manière asynchrone tout comme elle. Voici un exemple : Vous voulez vous faire du café, mais vous vous rendez compte que vous n'avez plus de crème et de sucre.

Première approche :

- Mettre du café dans votre machine.
- Aller faire vos courses pendant que la machine fait couler le café.

- Acheter de la crème et du sucre.
- Rentrer chez vous.
- Boire votre tasse de café.
- Profiter de la vie !

Seconde approche :

- Aller faire vos courses.
- Acheter de la crème et du sucre.
- Rentrer chez vous.
- Mettre du café dans votre machine.
- Regarder impatiemment la cafetière se remplir.
- Expérimenter le manque de caféine.
- Et enfin, boire votre tasse de café.

Grâce à la première approche, on peut clairement voir la différence de gestion de l'espace et du temps. C'est grâce à cela que cette architecture est un atout primordiale pour assurer un système responsive.

Resilient :

La plupart des applications sont conçus par rapport à un fonctionnement idéal. C'est à dire qu'elle ne prévoient pas de gérer correctement les erreurs qui peuvent intervenir plus souvent que ce qu'on pourrait croire. Cela à pour effet de ne pas garantir une disponibilité continu et peut provoquer la perte de crédibilité d'un service. La résilience est là pour pallier à ce problème, elle à pour but de récupérer les erreurs émises et de les traiter correctement afin de ne pas provoquer d'interruption de service et de ne pas impacter l'expérience utilisateur.

Scalable :

La résilience et l'élasticité vont de pair dans la construction d'une architecture réactive. L'élasticité permet d'adapter facilement le système à la demande et d'assurer sa réactivité peu importe la charge qu'il subit. L'élasticité est un point très important, lorsque votre plateforme reçoit énormément de connexion cela veut dire que votre service connaît un succès important, c'est donc le pire moment pour avoir un service non disponible. Cela entrainerait une perte de crédibilité et de clients.

Il existe deux moyens différents de rendre élastique une application :

- La mise à l'échelle verticale
- La mise à l'échelle horizontale (Architecture Répartie)

La mise à l'échelle verticale consiste à maximiser l'utilisation des ressources de notre machine. Cela peut se faire par l'utilisation de programmes fonctionnant en asynchrone sur plusieurs threads. Tandis que la mise à l'échelle horizontale consiste à augmenter le nombre de machine afin d'avoir plus de ressources à notre disposition. Pour le moment on ne vas pas trop s'attarder sur la division horizontale car une partie lui est dédiée.

La mise à l'échelle verticale est certes la moins couteuse, mais ce n'est pas la plus simple à mettre en place. En effet le multithreading permet de tirer la maximum des performances de la machine, mais cela ajoute une certaine complexité au programme. Par exemple le fait de travailler avec des variables mutables entre différents threads n'est pas une tâche aisée, cela provoque donc des limitations à la mise à l'échelle

verticale. De plus, une fois avoir exploiter au maximum une machine en ayant mis en place la mise à l'échelle verticale, si on a encore besoin de ressources supplémentaire la mise à l'échelle horizontale devient indispensable.

Message-Driven :

Le Message-Driven Architecture est la base d'une architecture réactive. Une application dirigée par message peut être dirigée par des événements, par des acteurs ou par les deux.

Un système déclenché par événement est basé sur des événements qui sont surveillés par zéro observateur ou plus. Les événements ne pointent pas directement vers une destination en particulier, ils sont écoutés et les entités qui écoutent les événements vont interagir lorsque qu'ils en ont détecté un.

Un système dirigé par des acteurs est une extension de l'architecture de transmission de messages. Les messages sont envoyés à des destinataires précis, appelés acteurs. Les messages sont envoyés dans la boîte aux lettres des acteurs, et seront traités dès que l'acteur aura du temps.

A.2 Architecture Répartie

Une architecture répartie ou bien un système distribué représente tout simplement une mise à l'échelle verticale. C'est à dire un groupe de machines travaillant ensemble, mais en donnant l'impression que ce n'est qu'une seule machine.

Ces machines ont un état partagé, elles fonctionnent simultanément et peuvent tomber en panne indépendamment sans perturber le fonctionnement du reste du système. Cela peut permettre notamment d'attribuer facilement plus de ressource à une application lors d'une montée en charge.

Bibliographie

- [1] Julie MARTIN. *Les 5 V du Big Data*. url : <https://medium.com/@jm.julie.martin/les-5-v-du-big-data-1d0462896468>.
- [2] Zoiner Tejada et olprod. *Architectures Big Data*. url : <https://docs.microsoft.com/fr-fr/azure/architecture/data-guide/big-data>.
- [3] Christophe Parageaud. *Big Data, panorama des solutions*. url : <https://blog.ippon.fr/2016/03/31/big-data-panorama-des-solutions-2016/>.
- [4] Iman Samizadeh. *A brief introduction to two data processing architectures—Lambda and Kappa for Big Data*. url : <https://towardsdatascience.com/a-brief-introduction-to-two-data-processing-architectures-lambda-and-kappa-for-big-data-4f35c28005bb>.
- [5] Michael Verrilli. *From Lambda to Kappa : A Guide on Real-time Big Data Architectures*. url : <https://www.talend.com/blog/2017/08/28/lambda-kappa-real-time-big-data-architectures/>.
- [6] <https://www.tibco.com>. *What is a Message Broker?* url : <https://www.tibco.com/reference-center/what-is-a-message-broker>.
- [7] Anthony. *Introduction à Apache Kafka*. url : <https://medium.com/@AnthonyDasse/introduction-%C3%A0-apache-kafka-d126f2bb852b>.
- [8] tutorialspoint. *Apache Kafka - Introduction*. url : https://www.tutorialspoint.com/apache_kafka/apache_kafka_introduction.htm.
- [9] Apache. *What is ZooKeeper?* url : <https://zookeeper.apache.org/>.
- [10] Laura Shiff. *Real Time vs Batch Processing vs Stream Processing : What's The Difference?* url : <https://www.bmc.com/blogs/batch-processing-stream-processing-real-time/>.
- [11] streamlio. *Understanding Batch, Microbatch, and Streaming*. url : <https://streamlio/resources/tutorials/concepts/understanding-batch-microbatch-streaming>.
- [12] Kevin Webber. *What is Reactive Programming?* url : <https://blog.redelastic.com/what-is-reactive-programming-bc9fa7f4a7fc>.

Table des matières

1	Les architectures Big Data	9
1.1	Architecture Lambda	11
1.2	Architecture Kappa	14
2	Analyse des solutions logicielles existantes	17
2.1	Message Broker	17
2.1.1	Kafka	18
2.1.2	ActiveMQ	18
2.1.3	RabbitMQ	19
2.2	Ingestion/Extraction de données	19
2.2.1	Apache Nifi	20
2.2.2	Talend Open Studio	20
2.2.3	Solution maison	20
2.3	Traitement des données	21
2.3.1	Batch	21
2.3.1.1	Apache Spark	22
2.3.1.2	Hadoop MapReduce	22
2.3.2	Streaming	23
2.3.2.1	Apache Spark Streaming	23
2.3.2.2	Apache Storm	24
2.4	Stockage des données	24
2.4.1	Base de données de séries temporelles	25
2.4.1.1	OpenTSDB	25
2.4.1.2	InfluxDB	25
2.4.2	Base de données orientée graphe	26
2.4.2.1	Neo4j	26
2.4.2.2	JanusGraph	27
2.4.3	Base de données clés/valeurs	28
2.4.3.1	Redis	28
2.4.3.2	RocksDB	28

2.4.4	Moteur d'indexation	29
2.4.4.1	Elasticsearch	29
2.4.4.2	Apache Solr	30
2.4.5	Base de données orientée documents	30
2.4.5.1	CouchDB	31
2.4.5.2	CouchBase	31
2.4.5.3	MongoDB	31
2.4.6	Base de données à grandes colonnes	31
2.4.6.1	HBase	31
2.4.6.2	Cassandra	32
2.4.7	Système de fichiers	32
2.4.7.1	Hadoop HDFS	32
2.5	Requêtage des données	33
2.6	Visualisation et Analyse des données	33
2.6.1	Kibana	33
2.6.2	Banana	34
2.6.3	Grafana	34
2.6.4	D3.js	34
2.7	Orchestration	34
2.7.1	Apache Oozie	35
2.7.2	Cron	35
2.7.2.1	Conclusion	35
3	Critères d'analyse	37
3.1	Sélection d'architecture en entreprise	37
3.2	Critères pour le choix de l'architecture	38
3.3	Critères pour le choix des solutions logicielles	39
3.3.1	Ingestion des données	39
3.3.2	Message Broker	40
3.3.3	Traitement des données	41
3.3.3.1	Traitement par lots	41
3.3.3.2	Traitement en temps réel	41
3.3.4	Stockage des données	42

3.3.4.1	Base de données de séries temporelles	42
3.3.4.2	Base de données orientée graphe	42
3.3.4.3	Base de données clés/valeurs	42
3.3.4.4	Moteur d'indexation	42
3.3.4.5	Base de données documents	42
3.3.4.6	Base de données à grande colonne	42
3.3.5	Orchestration	42
3.3.6	Visualisation et Analyse des données	42
3.4	Pour aller plus loin	42
4	Comment évaluer l'architecture résultant de l'application des critères	45
4.1	Application des critères définis sur des cas d'utilisations réels	45
4.2	Évaluation des résultats	45
Annexe A	Les différents concepts du Big Data	49
A.1	Architecture Réactive	49
A.2	Architecture Répartie	51
Bibliographie		53

Table des figures

1	Schéma des 5V du Big Data	7
1.1	Composants d'une architecture Big Data	9
1.2	Schéma de l'architecture Lambda	13
1.3	Schéma de l'architecture Kappa	15
2.1	Schéma du principe Publisher(Producer)/Subscriber	18
2.2	Schéma d'un cluster Kafka et de ces composants	19
2.3	Schéma du traitement par batch	22
2.4	Schéma du traitement en streaming	23
2.5	Exemple d'un graphe dans une base de données orientée graphe . . .	26
2.6	Schéma du principe de stockage de cassandra	31
2.7	Schéma du principe de stockage de cassandra	32
A.1	Schéma de l'architecture réactive	49

Liste des tableaux

3.1	Table des critères pour le choix de l'architecture	39
3.2	Table des critères pour le choix entre une solution complète ou d'un programme personnalisé pour l'ingestion des données.	40
3.3	Table des critères pour le choix du logiciel d'agent de messages . . .	40
3.4	Table des critères pour le choix de la solution de traitement par lots. .	41
3.5	Table des critères pour le choix de la solution de traitement par lots. .	41
3.6	Table des critères pour le choix de la solution de traitement par lots. .	42